

Kapitel 1

Einleitung und Motivation

Vitronic Mautbrücken sind aufgrund ihrer schweren Erreichbarkeit und der Tatsache, dass sie über Autobahnen installiert sind, eine besondere Herausforderung im Bereich der Wartung. Jede Inspektion oder Reparatur erfordert nicht nur die Bereitstellung spezialisierter Techniker und Geräte, sondern auch eine präzise Planung, um Verkehrsstörungen zu minimieren und die Sicherheit sowohl der Wartungsteams als auch der Verkehrsteilnehmer zu gewährleisten.

Ein technischer Defekt erfordert häufig eine komplexe Koordination mehrerer Teams und führt zu Verkehrsstörungen. Dadurch entsteht die Notwendigkeit, Wartungseinsätze effizienter zu gestalten, um die Funktionalität der Infrastruktur und die Sicherheit der Verkehrsteilnehmenden sowie der Servicemitarbeitenden zu gewährleisten. Gleichzeitig wächst der Druck, diese Einsätze planbarer und seltener durchzuführen. Genau hier setzt die Motivation dieser Arbeit an: neue Methoden zu entwickeln, die eine präzise Überwachung des Zustands der Brücken ermöglichen, ohne ständige physische Präsenz vor Ort.

Diese Arbeit befasst sich konkret mit der **Smart Sensor Platform X1** - kurz **SSPX1**, einem System zur Erfassung, Verarbeitung und Weiterleitung von Bilddaten. Die vorhandenen Komponenten zur Mautüberwachung umfassen zwei Kameras, ein eingebettetes High-Performance-Computermodul mit GPU-Unterstützung, ein High-Power-LED-Blitzmodul sowie eine Stromversorgungshardware mit Weitbereichsspannungseingang. Die SSPX1 nutzt zahlreiche Sensordaten zur kontinuierlichen und sorgfältigen Überwachung des Systemzustands.

Predictive Maintenance nutzt diese Daten, um Ausfälle vorherzusagen. Sie basiert auf der Analyse von Echtzeitdaten, die aus einer Vielzahl von Sensoren entnommen werden können. Maschinelles Lernen bietet sich hier als effektive Methode an, um sich anbahnende Fehler und Ausfälle vorherzusagen und abzufangen. So können Ressourcen effizient genutzt und Ausfallzeiten minimiert werden [6].

Diese großen Datensätze werden über einen OPC UA Server zur Verfügung gestellt. OPC UA steht für *Open Platform Communication Unified Architecture* und ist ein Industriestandard für Datenaustausch sowie horizontale und vertikale Kommunikation, unter Anderem aufgrund seiner Herstellerunabhängigkeit [3]. Die Datenerfassung erfolgt lokal auf jeder SSPX1, welche im Zuge dessen auch einen eigenen Server betreibt, um die aufgenommenen Daten bereitzustellen. Auf diese Weise wird eine dezentra-

le Sammlung relevanter Parameter wie Temperatur, Leistung und Systemauslastung ermöglicht. Die kontinuierliche Überwachung und Speicherung dieser Daten in einer Datenbank bildet die Grundlage für die Entwicklung und Anwendung prädiktiver Wartungsstrategien.

Ein zentraler Aspekt dabei ist die Detektion von Anomalien, die als Abweichungen vom normalen Verhalten definiert werden [4]. In multivariaten Systemen erschwert die hohe Dimensionalität und Komplexität der Daten ihre Erkennung. Unüberwachte maschinelle Lernverfahren bzw. **Unsupervised Learning** erweisen sich hier als besonders vielversprechend, da sie Muster und Zusammenhänge in hochdimensionalen, unstrukturierten Datensätzen identifizieren können, ohne auf eine vorherige Datenkennzeichnung angewiesen zu sein [4, 7].

Ziel dieser Arbeit ist es, Unsupervised Learning Algorithmen für die Erkennung und Interpretation von Anomalien in heterogenen Datensätzen eines Systems in der Verkehrstechnik zu nutzen und damit die Effizienz von Predictive Maintenance in der Verkehrstechnik zu optimieren. Dies soll durch eine frühzeitige Identifikation potenzieller Fehler erreicht werden.

Dabei wird zunächst in Kap. 2 ein theoretischer Hintergrund über die Grundlagen von Predictive Maintenance und verschiedener Machine Learning Ansätze gegeben und warum sich Unsupervised Learning optimal für die hier genannten Zwecke eignet.

Kapitel 2

Predictive Maintenance

Die Notwendigkeit von Predictive Maintenance wird immer dringlicher, da viele moderne Systeme zunehmend komplex und hochvernetzt sind. Die Systeme erzeugen eine enorme Menge an Daten, die wertvolle Informationen über den Zustand des Systems liefern können. Predictive Maintenance nutzt diese Daten, um Ausfälle und Defekte vorherzusagen. So wird eine frühzeitige Intervention ermöglicht, die Ausfallzeiten minimiert und die Lebensdauer eines Systems verlängert. Jedoch haben alle Wartungsansätze ihre Daseinsberechtigung, aber auch Nachteile. Diese werden im Folgenden diskutiert.

2.1 Traditionelle Wartungsansätze

Zu den traditionellen Wartungsansätzen gehören die reaktive und die präventive Wartung. Bei der reaktiven oder auch korrektiven Wartung wird, gemäß der Namensgebung, erst dann gehandelt, wenn Fehler auftreten und Komponenten gänzlich ausfallen und nicht mehr funktionstüchtig sind. Der Vorteil dieser Methode liegt in der sehr geringen Planung und Überwachung. Für Komponenten, die nicht kritisch oder essenziell sind, oder die ein sehr geringes Ausfallrisiko aufweisen, kann die reaktive Wartung sinnvoll sein. Für alle anderen Bestandteile bzw. die Gesamtheit eines Systems ist sie jedoch höchst ineffizient, da Wartungsmaßnahmen erst dann veranlasst und geplant werden, wenn das System ausfällt. Zudem gestaltet sich die Diagnose dann auch als potenziell schwierig, da die Fehlerquelle noch gefunden werden muss [1].

Demgegenüber steht die präventive Wartung, die Maßnahmen am Ende eines vorher festgelegten Zeitintervalls oder nach Ablauf einer bestimmten Betriebsdauer festlegt. Üblicherweise orientieren sich diese Wartungsintervalle entweder an der MTTF (*Mean Time To Failure*) oder an der Badewannenkurve [2]. Dieser Ansatz hat gewisse Vorteile für Komponenten, die nicht im dauerhaften Betrieb sind, sofern ausreichend geschultes Personal vorhanden ist mit genügend Zeit, die Wartungsarbeiten durchzuführen. Nachteile liegen im potenziell schlechten Timing der Wartungsarbeiten, die entweder zu früh oder zu spät stattfinden. Ohne Überwachung des Systemzustands ist schwer absehbar, in welchem Stadium seiner Lebensdauer sich ein System befindet, und Komponenten, die noch eine gewisse Zeit weiterlaufen könnten, werden zu früh ausgetauscht. Durch die Wartung verkürzt sich auch die Betriebsdauer des ganzen Systems und verursacht vermeidbare Kosten [5].

Literaturverzeichnis

- [1] Khoulood Abdelli. “Machine Learning-Based Predictive Maintenance for Optical Networks”. PhD thesis. Kiel, 2022. URL: <https://nbn-resolving.org/urn:nbn:de:gbv:8:3-2023-00225-4>.
- [2] J. D. Andrews and T. R. Moss. *Reliability and Risk Assessment*. English. Vol. 2nd ed. London: John Wiley and Sons, Inc, 2002. URL: <https://search.ebscohost.com/login.aspx?direct=true&db=nlebk&AN=99982&lang=de&site=ehost-live>.
- [3] Wolfgang Babel. *Systemintegration in Industrie 4.0 und IoT. Vom Ethernet bis hin zum Internet und OPC UA*. 1st ed. 2024. Wiesbaden: Imprint: Springer Vieweg, 2024. 1585216161 pp. ISBN: 9783658429874.
- [4] Varun Chandola, Arindam Banerjee, and Vipin Kumar. “Anomaly Detection: A Survey”. In: *ACM Computing Surveys* 41.3 (July 2009), pp. 1–58. ISSN: 1557-7341. DOI: 10.1145/1541880.1541882.
- [5] C. Scheffer and P. Girdhar. *Practical Machinery Vibration Analysis and Predictive Maintenance*. Practical Machinery Vibration Analysis and Predictive Maintenance. Newnes, 2004. ISBN: 9780080480220. URL: <https://books.google.de/books?id=tAvT01t2mwkC>.
- [6] Diego Alejandro Tobon-Mejia et al. “A Data-Driven Failure Prognostics Method Based on Mixture of Gaussians Hidden Markov Models”. In: *IEEE Transactions on Reliability* 61.2 (June 2012), pp. 491–503. ISSN: 1558-1721. DOI: 10.1109/tr.2012.2194177.
- [7] Phillip Wenig. “Finding, Clustering, and Classifying Anomalies on Large and Multivariate Time Series”. Dissertation. Universität Potsdam, 2024. DOI: 10.25932/publishup-66043. URL: <https://publishup.uni-potsdam.de/frontdoor/index/index/docId/66043>.