

Kapitel 1

Einleitung und Motivation

Vitronic Mautbrücken sind aufgrund ihrer schweren Erreichbarkeit und der Tatsache, dass sie über Autobahnen installiert sind, eine besondere Herausforderung im Bereich der Wartung. Jede Inspektion oder Reparatur erfordert nicht nur die Bereitstellung spezialisierter Techniker und Geräte, sondern auch eine präzise Planung, um Verkehrsstörungen zu minimieren und die Sicherheit sowohl der Wartungsteams als auch der Verkehrsteilnehmer zu gewährleisten.

Ein technischer Defekt erfordert häufig eine komplexe Koordination mehrerer Teams und führt zu Verkehrsstörungen. Dadurch entsteht die Notwendigkeit, Wartungseinsätze effizienter zu gestalten und diese Einsätze planbarer und seltener durchzuführen. Genau hier setzt die Motivation dieser Arbeit an: neue Methoden zu entwickeln, die eine präzise Überwachung des Zustands der Brücken ermöglichen, ohne ständige physische Präsenz vor Ort.

Diese Arbeit befasst sich konkret mit der **Smart Sensor Platform X1** - kurz **SSPX1**, einem System zur Erfassung, Verarbeitung und Weiterleitung von Bilddaten. Die vorhandenen Komponenten zur Mautüberwachung umfassen zwei Kameras, ein eingebettetes High-Performance-Computermodule mit GPU-Unterstützung, ein High-Power-LED-Blitzmodul sowie eine Stromversorgungshardware mit Weitbereichsspannungseingang. Die SSPX1 nutzt zahlreiche Sensordaten zur kontinuierlichen und sorgfältigen Überwachung des Systemzustands.

Predictive Maintenance nutzt diese Daten, um Ausfälle vorherzusagen. Sie basiert auf der Analyse von Echtzeitdaten, die aus einer Vielzahl von Sensoren entnommen werden können. Mithilfe von maschinellem Lernen können sich anbahnende Fehler und Ausfälle vorhergesagt und abgefangen werden. So können Ressourcen effizient genutzt und Ausfallzeiten minimiert werden [13, S. 3].

In diesem Kontext spielt OPC UA eine wichtige Rolle. OPC UA steht für *Open Platform Communication Unified Architecture* und wird in Abs. 4.1 grundlegend erläutert. Die Datenerfassung erfolgt lokal auf jeder SSPX1, welche im Zuge dessen auch einen eigenen OPC UA Server betreibt, um die aufgenommenen Daten bereitzustellen. Auf diese Weise wird eine dezentrale Sammlung relevanter Parameter wie Temperatur, Leistung und Systemauslastung ermöglicht. Die kontinuierliche Überwachung und Speicherung dieser Daten in einer Datenbank bildet die Grundlage für die Entwicklung und Anwendung prädiktiver Wartungsstrategien.

Ein zentraler Aspekt dabei ist die Detektion von Anomalien, die als Abweichungen vom normalen Verhalten definiert werden [5]. In multivariaten Systemen erschwert die hohe Dimensionalität und Komplexität der Daten ihre Erkennung. Unüberwachte maschinelle Lernverfahren bzw. **Unsupervised Learning** erweisen sich hier als besonders vielversprechend, da sie Muster und Zusammenhänge in hochdimensionalen, unstrukturierten Datensätzen identifizieren können, ohne auf eine vorherige Datenkennzeichnung angewiesen zu sein [5] [16, S. 22–24].

Ziel dieser Arbeit ist es, Unsupervised Learning Algorithmen für die Erkennung und Interpretation von Anomalien in heterogenen Datensätzen eines Systems in der Verkehrstechnik zu nutzen und damit die Effizienz von Wartungseinsätzen für Vitronic zu optimieren. Dies soll durch eine frühzeitige Identifikation potenzieller Fehler erreicht werden.

Dabei wird zunächst in Kap. 2 die konkrete Zielsetzung im Rahmen dieser Arbeit formuliert und eingeordnet. Kap. 3 gibt dann einen Überblick über konventionelle Wartungsansätze, bevor das Konzept zu Predictive Maintenance vorgestellt wird, welches als Konsequenz aus der Entwicklung des Anomaliedetektionssystems aus dieser Arbeit herausgeht. Danach grenzt Kap. 4 die Rahmenbedingungen der Arbeit ein bzgl. der relevanten Grundbausteine, auf denen die Arbeit aufbaut.

Kapitel 2

Zielsetzung

Eine effiziente Ressourcennutzung ist für Unternehmen von zentraler Bedeutung. Produktionsprobleme können dabei enorme finanzielle Verluste verursachen, wie das Beispiel von Volkswagen im Jahr 2016 zeigt: Durch Störungen im Fertigungsprozess entstand ein wöchentlicher Schaden von bis zu 400 Millionen Euro [9]. Zudem zeigen Studien, dass je nach Branche zwischen 15 und 70 % der Produktionskosten auf wartungstechnische Ursachen zurückzuführen sind [4].

Jedoch liegt der Fokus dieser Arbeit nicht auf wirtschaftlichen Faktoren, trotzdem ist zu erwähnen, dass neue, effiziente Wartungsstrategien basierend auf der Überwachung wichtiger Systemparameter insgesamt eine wirtschaftlichere und kostengünstigere Alternative zu klassischen Wartungsstrategien (vgl. Abs. 3.1) darstellen [6] [12, S. 64–65].

Der Fokus liegt vielmehr in der Entwicklung, Erprobung und Umsetzung der zugrundeliegenden technischen Fragestellung: **Wie können Unsupervised Learning Algorithmen zur Anomaliedetektion genutzt werden, um zur Entwicklung effizientes Wartungssystem beizutragen?**

Alle weiteren, impliziten Konsequenzen, wie eine Reduzierung der Downtime, Verbesserung der Systemzuverlässigkeit und Gerätelaufzeit, eine Verbesserung der Produktqualität oder die Redundanz eines großen Ersatzteillagers [12, S. 61–62] [13, S. 5] wollen im Rahmen dieser Arbeit nicht betrachtet werden.

Die starke Eingrenzung der Zielsetzung erfolgt auch aufgrund des gegebenen zeitlichen Rahmens der Arbeit von zehn Wochen. Das primäre Ziel ist also vielmehr die Erprobung verschiedener, sich als potenziell geeignet herausstellender, Machine Learning Algorithmen zur Anomaliedetektion. Dabei gibt es aufgrund der sich zum Teil sehr grundlegend unterscheidenden Arten von Anomalien entsprechend pro Anomalietyp separate Kandidaten. Die voneinander abweichenden Anomaliearten und die dafür jeweils nominierten Algorithmen werden in Kap. 5 vorgestellt und erläutert.

Zur Bewertung und Einordnung der Ergebnisse der Algorithmen ist auch eine Evaluierungsmethode notwendig. Allerdings soll diese nicht vollautomatisiert sein, sondern nach dem sog. *Human-in-the-Loop* Ansatz geschehen. So kann die Expertise geschulter und erfahrener Mitarbeitenden in die Evaluierung miteingebunden werden, zur besseren Beurteilung und Korrektur der Ergebnisse [7].

Schlussendlich und ausblickend soll diese Arbeit einen Beitrag zu besser getimten Wartungseinsätzen beitragen - nicht nur für die SSPX1, sondern für viele, weitere Systeme der Vitronic Produktfamilie, da die zu Grunde liegenden, analysierten Parameter nicht SSPX1-exklusiv sind.

Kapitel 3

Predictive Maintenance

Die zunehmende Komplexität und Vernetzung moderner Systeme erfordert effizientere Wartungsstrategien. Predictive Maintenance nutzt die enormen Datenmengen solcher Systeme, um drohende Defekte frühzeitig zu erkennen und Ausfälle zu verhindern. Dadurch können Ausfallzeiten minimiert und die Lebensdauer der Systeme verlängert werden.

Nach dem ISO 13379-1 Standard [14] wird Predictive Maintenance als Wartungsstrategie definiert, die die Zustandsüberwachung eines Systems oder einer Komponente nutzt, um Zustandsänderungen zu detektieren, die auf bevorstehende Ausfälle hinweisen können. Eine passende Analogie findet sich in der Medizin: Wenn der menschliche Körper Anzeichen einer bevorstehenden Krankheit zeigt, können diese Symptome vom Arzt genutzt werden, um eine Diagnose zu stellen und entsprechende Maßnahmen zu ergreifen. Diese Zustandsüberwachung erlaubt es, dass Wartungsarbeiten zu einem Zeitpunkt stattfinden können, der für alle Beteiligten passend ist und minimale Einschnitte in Produktions- oder Prozesslaufzeiten bedeutet [13].

Im Vergleich zu traditionellen Ansätzen bietet Predictive Maintenance signifikante Vorteile, doch auch die klassischen Methoden haben ihre Berechtigungen. Diese werden im Folgenden diskutiert.

3.1 Traditionelle Wartungsansätze

Zu den traditionellen Wartungsansätzen gehören die reaktive und die präventive Wartung. Bei der reaktiven oder auch korrektiven Wartung wird, gemäß der Namensgebung, erst bei vollständigem Ausfall von Komponenten gehandelt. Der Vorteil dieser Methode liegt in der sehr geringen Planung und Überwachung. Für Komponenten, die nicht kritisch oder essenziell sind, oder die ein sehr geringes Ausfallrisiko aufweisen, kann die reaktive Wartung sinnvoll sein. Für alle anderen Bestandteile bzw. die Gesamtheit eines Systems ist sie jedoch höchst ineffizient, da Wartungsmaßnahmen erst dann veranlasst und geplant werden, wenn das System ausfällt. Zudem gestaltet sich die Diagnose dann auch als potenziell schwierig, da die Fehlerquelle noch gefunden werden muss [1].

Demgegenüber steht die präventive Wartung, die Maßnahmen am Ende eines vorher festgelegten Zeitintervalls oder nach Ablauf einer bestimmten Betriebsdauer festlegt. Üblicherweise orientieren sich

diese Wartungsintervalle entweder an der MTTF (*Mean Time To Failure*) oder an der Badewannenkurve [2]. Dieser Ansatz hat gewisse Vorteile für Komponenten, die nicht im dauerhaften Betrieb sind, sofern ausreichend geschultes Personal vorhanden ist mit genügend Zeit, die Wartungsarbeiten durchzuführen. Nachteile liegen im potenziell schlechten Timing der Wartungsarbeiten, die entweder zu früh oder zu spät stattfinden. Ohne Überwachung des Systemzustands ist schwer absehbar, in welchem Stadium seiner Lebensdauer sich ein System befindet, und Komponenten, die noch eine gewisse Zeit weiterlaufen könnten, werden zu früh ausgetauscht. Durch die Wartung verkürzt sich auch die Betriebsdauer des ganzen Systems und verursacht vermeidbare Kosten [13].

Kapitel 4

Framework

Im Gegensatz zu diesen etablierten Methoden basiert Predictive Maintenance auf einem völlig anderen Ansatz, der auf kontinuierlicher Überwachung und Datenanalyse beruht. In Anlehnung an Krupitzer et al. [9] werden für die Entwicklung einer Predictive Maintenance Lösung im Kontext des SSPX1 Mautüberwachungssystems einige Rahmenbedingungen skizziert. Diese lassen sich gem. Abb. 4.1 kategorisieren.




Abbildung 4.1: Framework zur Entwicklung eines Predictive Maintenance Systems

4.1 Technologische Grundlagen

Die technologischen Grundlagen dieser Arbeit stützen sich auf die in der SSPX1 verbauten Sensoren, die präzise Systemdaten erfassen und kontinuierlich überwachen. Zu den erfassten Parametern gehören unter anderem die Temperatur und Auslastung von GPU und CPU, die Auslastung des Arbeitsspeichers sowie die Strom- und Leistungsaufnahme des Blitzmoduls.

Ein zentraler Baustein ist die Nutzung moderner IoT-Technologien in Kombination mit dem industriellen Kommunikationsstandard OPC UA. Dieser Standard ermöglicht einen effizienten und sicheren Zugriff auf die Sensordaten der SSPX1 und deren Übertragung an eine Anwenderschnittstelle nach dem Client-Server-Prinzip [3].

Da die Sensoren teilweise von unterschiedlichen Herstellern stammen und Messdaten in verschiedenen Formaten bereitstellen, sorgt OPC UA für eine einheitliche und standardisierte Kommunikation. Die Daten werden dabei im kompakten *OPC UA Binary*-Format [8] erfasst, wodurch eine performante und ressourcenschonende Datenübertragung ermöglicht wird. Anschließend werden die Daten an den OPC UA-Server übermittelt und in der zugrundeliegenden SQL-Datenbank gespeichert.

Durch diese Architektur wird eine herstellerübergreifende Interoperabilität gewährleistet, die OPC UA besonders für den betrachteten Anwendungsfall geeignet macht. Die hohe Skalierbarkeit und Erweiterbarkeit des Standards ermöglicht zudem die einfache Integration weiterer Sensoren und Systeme, wodurch zukünftige Erweiterungen ohne grundlegende Anpassungen der bestehenden Infrastruktur möglich sind.

Ein weiterer Vorteil der Nutzung von OPC UA liegt in der serviceorientierten Architektur, die eine flexible Kommunikation zwischen Client und Server ermöglicht. Der Client fungiert hierbei als Kommunikationsbrücke, die Anfragen und Antworten zwischen der Anwenderschnittstelle und dem Server verwaltet. Die OPC UA-Kommunikations-Stacks unterstützen dabei die Datenverarbeitung und gewährleisten eine robuste Übertragung, indem sie eng mit dem Speicher- und Dateisystem des Servers zusammenarbeiten. Zu den wesentlichen Ereignissen der Client-Server-Kommunikation gehören [3, 8, 11]:

- **Message Requests:** Anfragen des Clients zur Datenabfrage oder -übertragung
- **Message Responses:** Antworten des Servers auf die Anfragen des Clients
- **Order Requests:** Aufrufe zur Ausführung bestimmter Serveraktionen
- **Notifications:** Benachrichtigungen über Änderungen oder Ereignisse im System

Darüber hinaus kann der OPC UA-Server als Bindeglied zwischen mehreren physischen Geräten oder auch als Cloud-Service fungieren, was die Skalierbarkeit weiter erhöht und die Nutzung in verteilten Systemen erlaubt. Die Kombination aus präzisen Sensordaten, standardisierter Kommunikation und einer skalierbaren Architektur bildet die technologische Grundlage für die Analyse und Umsetzung von Predictive Maintenance im Rahmen dieser Arbeit.

4.2 Zustandsüberwachung

Ein wesentlicher Grund für ineffiziente Wartungsmaßnahmen liegt im unzureichenden Zugang zu Daten, die frühe Hinweise auf potenzielle Schäden oder Ausfälle liefern könnten [12]. Predictive Maintenance basiert auf der Voraussetzung, dass Daten über den Zustand des betreffenden Systems oder der betreffenden Komponente zuverlässig verfügbar sind. Die Bereitstellung der Daten erfolgt wie oben beschrieben mithilfe von OPC UA und die Zustandsüberwachung sensorbasiert.

Zu Beginn der Arbeit und in der Entwicklungsphase wird die Zustandsüberwachung einen inspektionsbasierten Ansatz verfolgen. Das bedeutet, dass nach willkürlichen Intervallen immer auf die vom OPC UA Server zur Verfügung gestellten Daten zugegriffen wird und diese Datensätze dann analysiert und weiterverarbeitet werden. Die Wahl dieser Methode basiert auf der geringeren Komplexität der Implementierung in frühen Entwicklungsphasen und hat zur Folge, dass ein konsistenter Datensatz einen besseren Vergleich und Feinabstimmung von Parametern der Analysetools ermöglicht.

Online Predictive Maintenance erweitert diesen Ansatz, indem sie eine kontinuierliche Überwachung des Systemzustands in Echtzeit ermöglicht. Dabei werden Daten oder andere relevante Parameter in regelmäßigen Abständen automatisch erfasst. Nicht alle erfassten Daten werden analysiert; vielmehr wird gezielt ausgewählt, welche Informationen für die Analyse und die Ableitung von Wartungsmaßnahmen notwendig sind [10].

Die automatisierte Datenweiterverarbeitung als Teil der Online Predictive Maintenance erfolgt zu einem späteren Zeitpunkt und wird zu Beginn noch nicht verfolgt, kann aber als schlussendliches Ziel gesetzt werden. So kann das in dieser Arbeit entwickelte System im laufenden Betrieb optimal und effizient genutzt werden.

4.3 Datenverarbeitung

Durch die kontinuierliche Aggregation von Messdaten der SSPX1 entstehen sehr große, hochdimensionale Datensätze. Jeder Datenpunkt in der Zeitserie S ist mehrdimensional. Formell lässt sich eine Zeitserie S der Länge n und Dimensionalität d wie in Gl. 4.1a definieren. x_i^j ist der i -te Skalar der j -ten Dimension einer Serie S . Für die Dimension $j = 0, \dots, d$ der Zeitserie S entspricht jede Dimension einem Messwert im Datensatz. Da es sich um eine Zeitserie handelt, entsprechen die Indizes $i = 0, \dots, n$ den Zeitstempeln der aufgenommenen Messwerte [16].

$$S = \begin{bmatrix} x_0^0 & \cdots & x_0^d \\ \vdots & \ddots & \vdots \\ x_n^0 & \cdots & x_n^d \end{bmatrix} \quad (\text{a}) \tag{4.1}$$

$$S = \sum_{i=0}^n \sum_{j=0}^d x_i^j \cdot E_{ij} \quad (\text{b})$$

Alternativ kann die Zeitserie S wie Gl. 4.1b in auch als Linearkombination von Standardmatrizen geschrieben werden [15, S. 8]. Die elementweise Darstellung beschreibt die Matrix S als Summe von gewichteten Standardmatrizen E_{ij} , wobei jede Standardmatrix E_{ij} genau an der Position (i, j) den Wert 1 hat und sonst 0 ist.

Kapitel 5

Anomaliedetektion

Literaturverzeichnis

- [1] Khoulood Abdelli. “Machine Learning-Based Predictive Maintenance for Optical Networks”. PhD thesis. Kiel, 2022. URL: <https://nbn-resolving.org/urn:nbn:de:gbv:8:3-2023-00225-4>.
- [2] J. D. Andrews and T. R. Moss. *Reliability and Risk Assessment*. English. Vol. 2nd ed. London: John Wiley and Sons, Inc, 2002. URL: <https://search.ebscohost.com/login.aspx?direct=true&db=nlebk&AN=99982&lang=de&site=ehost-live>.
- [3] Wolfgang Babel. *Systemintegration in Industrie 4.0 und IoT. Vom Ethernet bis hin zum Internet und OPC UA*. 1st ed. 2024. Wiesbaden: Imprint: Springer Vieweg, 2024. 1585216161 pp. ISBN: 9783658429874.
- [4] M Bevilacqua and M Braglia. “The analytic hierarchy process applied to maintenance strategy selection”. In: *Reliability Engineering & System Safety* 70.1 (Oct. 2000), pp. 71–83. ISSN: 0951-8320. DOI: 10.1016/S0951-8320(00)00047-8.
- [5] Varun Chandola, Arindam Banerjee, and Vipin Kumar. “Anomaly Detection: A Survey”. In: *ACM Computing Surveys* 41.3 (July 2009), pp. 1–58. ISSN: 1557-7341. DOI: 10.1145/1541880.1541882.
- [6] E. Deloux, B. Castanier, and C. Bérenguer. “Predictive maintenance policy for a gradually deteriorating system subject to stress”. In: *Reliability Engineering & System Safety* 94.2 (Feb. 2009), pp. 418–431. ISSN: 0951-8320. DOI: 10.1016/j.ress.2008.04.002.
- [7] Ziquan Deng et al. “A Reliable Framework for Human-in-the-Loop Anomaly Detection in Time Series”. In: *ArXiv abs/2405.03234* (2024). URL: <https://api.semanticscholar.org/CorpusID:269605667>.
- [8] International Electrotechnical Commission. *IEC 62541-1: OPC Unified Architecture – Part 5: Information Model*. Accessed: 2024-12-16. IEC, 2020. URL: <https://webstore.iec.ch/en/publication/61114>.
- [9] Christian Krupitzer et al. “A Survey on Predictive Maintenance for Industry 4.0”. In: *ArXiv abs/2002.08224* (2020). URL: <https://api.semanticscholar.org/CorpusID:211171556>.
- [10] John Lindström et al. “Towards Intelligent and Sustainable Production: Combining and Integrating Online Predictive Maintenance and Continuous Quality Control”. In: *Procedia CIRP* 63 (2017), pp. 443–448. ISSN: 2212-8271. DOI: 10.1016/j.procir.2017.03.099.

- [11] Bingqiang Mao et al. “OPC UA Application Study in Oil and Gas Pipeline Network Monitoring Data Forwarding”. In: *EAI Endorsed Transactions on Energy Web* 11 (Mar. 2024). ISSN: 2032-944X. DOI: 10.4108/ew.5245.
- [12] R. Keith Mobley. *An Introduction to Predictive Maintenance*. Plant Engineering. Butterworth-Heinemann, 2002. ISBN: 9780080478692.
- [13] C. Scheffer and P. Girdhar. *Practical Machinery Vibration Analysis and Predictive Maintenance*. Practical Machinery Vibration Analysis and Predictive Maintenance. Newnes, 2004. ISBN: 9780080480220. URL: <https://books.google.de/books?id=tAvT01t2mwkC>.
- [14] International Organization for Standardization. *ISO 13379-1 : Condition Monitoring and Diagnostics of Machines: General Guidelines on Data Interpretation and Diagnostics Techniques. - Part 1 General Guidelines*. International standard. International Organization for Standardization, 2012. URL: <https://books.google.de/books?id=qgSJzwEACAAJ>.
- [15] Christian Voigt and Jürgen Adamy. *Formelsammlung der Matrizenrechnung*. Technik 10-2012. München: Oldenbourg, 2012. 162 pp. ISBN: 9783486583502.
- [16] Phillip Wenig. “Finding, Clustering, and Classifying Anomalies on Large and Multivariate Time Series”. Dissertation. Universität Potsdam, 2024. DOI: 10.25932/publishup-66043. URL: <https://publishup.uni-potsdam.de/frontdoor/index/index/docId/66043>.