

Kapitel 1

Einleitung und Motivation

Vitronic Mautbrücken sind aufgrund ihrer schweren Erreichbarkeit und der Tatsache, dass sie über Autobahnen installiert sind, eine besondere Herausforderung im Bereich der Wartung. Jede Inspektion oder Reparatur erfordert nicht nur die Bereitstellung spezialisierter Techniker und Geräte, sondern auch eine präzise Planung, um Verkehrsstörungen zu minimieren und die Sicherheit sowohl der Wartungsteams als auch der Verkehrsteilnehmer zu gewährleisten.

Ein technischer Defekt erfordert häufig eine komplexe Koordination mehrerer Teams und führt zu Verkehrsstörungen. Dadurch entsteht die Notwendigkeit, Wartungseinsätze effizienter zu gestalten und diese Einsätze planbarer und seltener durchzuführen. Genau hier setzt die Motivation dieser Arbeit an: neue Methoden zu entwickeln, die eine präzise Überwachung des Zustands der Brücken ermöglichen, ohne ständige physische Präsenz vor Ort.

Diese Arbeit befasst sich konkret mit der **Smart Sensor Platform X1** - kurz **SSPX1**, einem System zur Erfassung, Verarbeitung und Weiterleitung von Bilddaten. Die vorhandenen Komponenten zur Mautüberwachung umfassen zwei Kameras, ein eingebettetes High-Performance-Computermodule mit GPU-Unterstützung, ein High-Power-LED-Blitzmodul sowie eine Stromversorgungshardware mit Weitbereichsspannungseingang. Die SSPX1 nutzt zahlreiche Sensordaten zur kontinuierlichen und sorgfältigen Überwachung des Systemzustands.

Predictive Maintenance nutzt diese Daten, um Ausfälle vorherzusagen. Sie basiert auf der Analyse von Echtzeitdaten, die aus einer Vielzahl von Sensoren entnommen werden können. Mithilfe von maschinellem Lernen können sich anbahnende Fehler und Ausfälle vorhergesagt und abgefangen werden. So können Ressourcen effizient genutzt und Ausfallzeiten minimiert werden [21, S. 3].

In diesem Kontext spielt OPC UA eine wichtige Rolle. OPC UA steht für *Open Platform Communication Unified Architecture* und wird in Abs. 4.1 grundlegend erläutert. Die Datenerfassung erfolgt lokal auf jeder SSPX1, welche im Zuge dessen auch einen eigenen OPC UA Server betreibt, um die aufgenommenen Daten bereitzustellen. Auf diese Weise wird eine dezentrale Sammlung relevanter Parameter wie Temperatur, Leistung und Systemauslastung ermöglicht. Die kontinuierliche Überwachung und Speicherung dieser Daten in einer Datenbank bildet die Grundlage für die Entwicklung und Anwendung prädiktiver Wartungsstrategien.

Ein zentraler Aspekt dabei ist die Detektion von Anomalien, die als Abweichungen vom normalen Verhalten definiert werden [9]. In multivariaten Systemen erschwert die hohe Dimensionalität und Komplexität der Daten ihre Erkennung. Unüberwachte maschinelle Lernverfahren bzw. **Unsupervised Learning** erweisen sich hier als besonders vielversprechend, da sie Muster und Zusammenhänge in hochdimensionalen, unstrukturierten Datensätzen identifizieren können, ohne auf eine vorherige Datenkennzeichnung angewiesen zu sein [9] [25, S. 22–24].

Ziel dieser Arbeit ist es, Unsupervised Learning Algorithmen für die Erkennung und Interpretation von Anomalien in heterogenen Datensätzen eines Systems in der Verkehrstechnik zu nutzen und damit die Effizienz von Wartungseinsätzen für Vitronic zu optimieren. Dies soll durch eine frühzeitige Identifikation potenzieller Fehler erreicht werden.

Dabei wird zunächst in Kap. 2 die konkrete Zielsetzung im Rahmen dieser Arbeit formuliert und eingeordnet. Kap. 3 gibt dann einen Überblick über konventionelle Wartungsansätze, bevor das Konzept zu Predictive Maintenance vorgestellt wird, welches als Konsequenz aus der Entwicklung des Anomaliedetektionssystems aus dieser Arbeit herausgeht. Danach grenzt Kap. 4 die Rahmenbedingungen der Arbeit ein bzgl. der relevanten Grundbausteine, auf denen die Arbeit aufbaut.

Kapitel 2

Zielsetzung

Eine effiziente Ressourcennutzung ist für Unternehmen von zentraler Bedeutung. Produktionsprobleme können dabei enorme finanzielle Verluste verursachen, wie das Beispiel von Volkswagen im Jahr 2016 zeigt: Durch Störungen im Fertigungsprozess entstand ein wöchentlicher Schaden von bis zu 400 Millionen Euro [15]. Zudem zeigen Studien, dass je nach Branche zwischen 15 und 70 % der Produktionskosten auf wartungstechnische Ursachen zurückzuführen sind [5].

Jedoch liegt der Fokus dieser Arbeit nicht auf wirtschaftlichen Faktoren. Trotzdem ist zu erwähnen, dass neue, effiziente Wartungsstrategien basierend auf der Überwachung wichtiger Systemparameter insgesamt eine wirtschaftlichere und kostengünstigere Alternative zu klassischen Wartungsstrategien (vgl. Abs. 3.1) darstellen [11] [18, S. 64–65].

Der Fokus liegt vielmehr in der Entwicklung, Erprobung und Umsetzung der zugrundeliegenden technischen Fragestellung: **Wie können Unsupervised Learning Algorithmen zur Anomaliedetektion genutzt werden, um zur Entwicklung eines effizienten Wartungssystems beizutragen?**

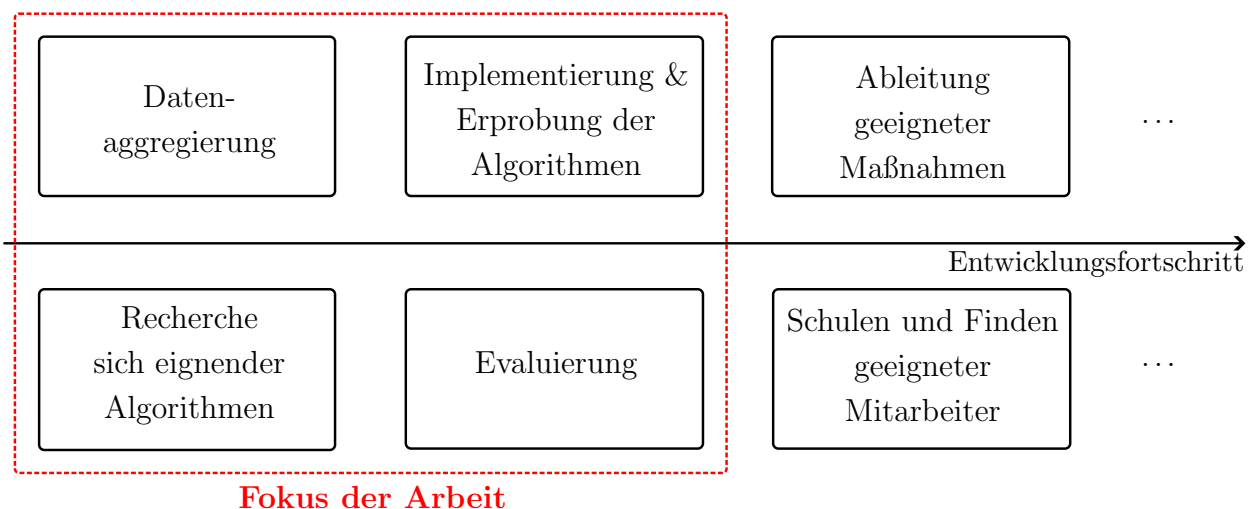


Abbildung 2.1: Entwicklungsprozess eines auf Predictive Maintenance basierenden Wartungssystems

Alle weiteren, impliziten Konsequenzen, wie eine Reduzierung der Downtime, Verbesserung der Systemzuverlässigkeit und Gerätelaufzeit, eine Verbesserung der Produktqualität oder die Redundanz eines großen Ersatzteillagers [18, S. 61–62] [21, S. 5] wollen im Rahmen dieser Arbeit nicht betrachtet werden.

Die starke Eingrenzung der Zielsetzung erfolgt auch aufgrund des gegebenen zeitlichen Rahmens der Arbeit von zehn Wochen. Das primäre Ziel ist also vielmehr die Erprobung verschiedener, sich als potenziell geeignet herausstellender, Machine Learning Algorithmen zur Anomaliedetektion. Dabei gibt es aufgrund der sich zum Teil sehr grundlegend unterscheidenden Arten von Anomalien entsprechend pro Anomalietyp separate Kandidaten. Die voneinander abweichenden Anomaliearten und die dafür jeweils nominierten Algorithmen werden in Kap. 5 vorgestellt und erläutert.

Die Erprobung der einzelnen Algorithmen erfolgt anhand der Anomalietypen, denen sie am besten zugeordnet werden können. Doch in Studien zeigt sich, dass einzelne Algorithmen auch interdisziplinär, also für mehrere, sehr unterschiedliche Anomalietypen, gut abschneiden [25, S. 30 - 31][22]. Daher sollen alle Algorithmen auch überschneidend getestet werden, um ein ganzheitliches Bild zu erhalten. Der Kontext der Arbeit soll an dieser Stelle noch einmal hervorgehoben werden. Für industrielle Zwecke ist es vorteilhafter, sich auf eine weniger umfangreiche Lösung zu konzentrieren, mit der aber mehrere Fehlerfälle abgedeckt oder vorhergesagt werden können, statt einzelne, hochspezialisierte Lösungen zu finden. Die Robustheit eines Algorithmus ist daher genauso wichtig wie die Fähigkeit, jede Anomalie bis ins letzte Detail zu erkennen. Auch diese Einordnung soll in der Findung der optimalen Lösung berücksichtigt werden.

Zur Bewertung und Einordnung der Ergebnisse der Algorithmen ist auch eine Evaluierungsmethode notwendig. Allerdings soll diese nicht vollautomatisiert sein, sondern nach dem sog. *Human-in-the-Loop* Ansatz geschehen. So kann die Expertise geschulter und erfahrener Mitarbeitenden in die Evaluierung miteingebunden werden, zur besseren Beurteilung und Korrektur der Ergebnisse [12].

Schlussendlich und ausblickend soll diese Arbeit einen Beitrag zu besser getimten Wartungseinsätzen beitragen - nicht nur für die SSPX1, sondern für weitere Systeme der Vitronic Produktfamilie, da die zu Grunde liegenden, analysierten Parameter nicht exklusiv zur SSPX1 gehören.

Kapitel 3

Wartungsstrategien

Die zunehmende Komplexität und Vernetzung moderner Systeme erfordert effizientere Wartungsstrategien. Predictive Maintenance nutzt die enormen Datenmengen solcher Systeme, um drohende Defekte frühzeitig zu erkennen und Ausfälle zu verhindern. Dadurch können Ausfallzeiten minimiert und die Lebensdauer der Systeme verlängert werden.

Im Vergleich zu traditionellen Ansätzen bietet Predictive Maintenance signifikante Vorteile, doch auch die klassischen Methoden haben ihre Berechtigungen. Diese werden im Folgenden diskutiert.

3.1 Traditionelle Wartungsansätze

Zu den traditionellen Wartungsansätzen gehören die reaktive und die präventive Wartung. Bei der reaktiven oder auch korrektiven Wartung wird, gemäß der Namensgebung, erst bei vollständigem Ausfall von Komponenten gehandelt. Der Vorteil dieser Methode liegt in der sehr geringen Planung und Überwachung. Für Komponenten, die nicht kritisch oder essenziell sind, oder die ein sehr geringes Ausfallrisiko aufweisen, kann die reaktive Wartung sinnvoll sein. Für alle anderen Bestandteile bzw. die Gesamtheit eines Systems ist sie jedoch höchst ineffizient, da Wartungsmaßnahmen erst dann veranlasst und geplant werden, wenn das System ausfällt. Zudem gestaltet sich die Diagnose dann auch als potenziell schwierig, da die Fehlerquelle noch gefunden werden muss [1].

Demgegenüber steht die präventive Wartung, die Maßnahmen am Ende eines vorher festgelegten Zeitintervalls oder nach Ablauf einer bestimmten Betriebsdauer festlegt. Diese Zeitintervalle werden beispielsweise anhand der Badewannenkurve [2, S. 4], wie in Abb. 3.1 dargestellt, auf Basis von Erfahrungswerten oder empirischen Untersuchungen geschätzt. Die Badewannenkurve ist eine Darstellung der Ausfallverteilung, die die Wahrscheinlichkeitsverteilung von mechanischen oder elektrischen Defekten beschreibt. Dieser Ansatz hat gewisse Vorteile für Komponenten, die nicht im dauerhaften Betrieb sind, sofern ausreichend geschultes Personal vorhanden ist mit genügend Zeit, die Wartungsarbeiten durchzuführen. Nachteile liegen im potenziell schlechten Timing der Wartungsarbeiten, die entweder zu früh oder zu spät stattfinden. Ohne Überwachung des Systemzustands ist schwer absehbar, in welchem Stadium seiner Lebensdauer sich ein System befindet, und Komponenten, die noch eine gewisse

Zeit weiterlaufen könnten, werden zu früh ausgetauscht. Durch die Wartung verkürzt sich auch die Betriebsdauer des ganzen Systems und verursacht vermeidbare Kosten [21].




Abbildung 3.1: Badewannenkurve zur Visualisierung der Ausfallverteilung

3.2 Predictive Maintenance

Nach Mobley [18, S. 4] wird Predictive Maintenance als eine zustandsbasierte Wartungsstrategie definiert, die den tatsächlichen Betriebszustand von Anlagen und Systemen überwacht, um Wartungsaktivitäten bedarfsgerecht zu planen. Eine passende Analogie findet sich in der Medizin: Wenn der menschliche Körper Anzeichen einer bevorstehenden Krankheit zeigt, können diese Symptome vom Arzt genutzt werden, um eine Diagnose zu stellen. Dementsprechend werden dann Maßnahmen ergriffen, zum Beispiel wird eine Behandlung eingeleitet oder Medikamente verordnet. Diese Zustandsüberwachung erlaubt es, dass Wartungsarbeiten zu einem Zeitpunkt stattfinden können, der für alle Beteiligten passend ist und minimale Einschnitte in Produktions- oder Prozesslaufzeiten bedeutet [21, S. 3].

Anhand von Abb. 3.2 ist zu erkennen, welche vereinfachten Schritte zur erfolgreichen Implementierung eines Predictive Maintenance Systems erforderlich sind. Essentiell ist an erster Stelle eine adäquate Infrastruktur, die sämtliche Zustandsparameter erfasst und gleichzeitig in der Lage ist, die erfassten Daten auch bereitzustellen. Es müssen im nächsten Schritt Daten gesammelt werden, damit die im normalen Betriebszustand gültigen Schwellwerte ermittelt und festgelegt werden können. Anhand dieser wird dann im laufenden, mittlerweile aufgenommenen Betrieb festgestellt, ob Abweichungen von den Parametern im Normalbetrieb vorliegen. Demnach werden notwendige Wartungsarbeiten geplant und vorbereitet, wonach der Betrieb wieder ordnungsgemäß aufgenommen werden kann.

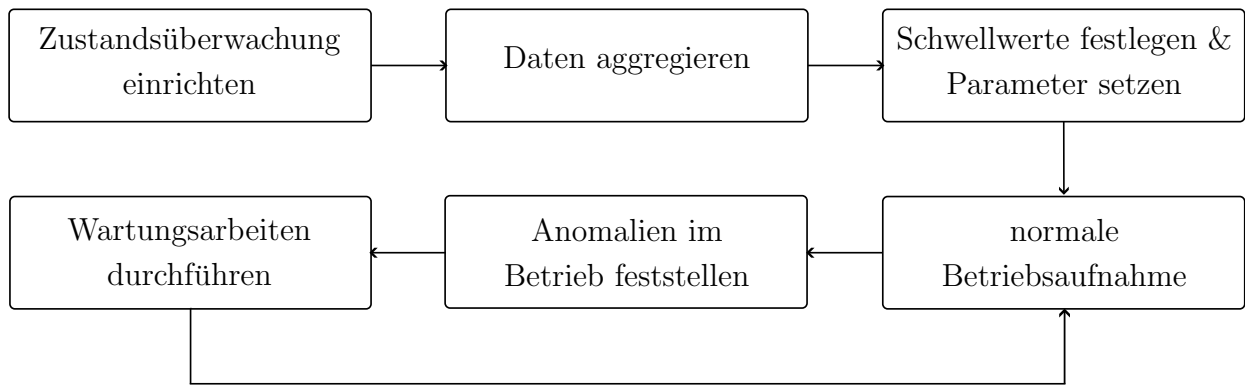


Abbildung 3.2: Workflow eines Predictive Maintenance Systems

Es stellt sich die Frage, welcher Anwendungsfall hauptsächlich interessant ist. In Kap. 2 wird bereits erläutert, in welchem Umfang eine Diagnose bzw. Prognose gestellt werden soll. Vorrangig ist die Detektion von anomalem Verhalten im laufenden Betrieb wie z. B. auftretende Alterserscheinungen oder Komponentenausfälle. Anhand dieser Anomalien soll durch zusätzlichen menschlichen Input entschieden werden, ob und wann ein Wartungseinsatz notwendig ist.

Predictive Maintenance ist keineswegs eine neue Erscheinung. Der Ansatz und erste Methoden zur Umsetzung bestehen bereits seit den 70er und 80er Jahren [20, 19] mit Techniken wie beispielsweise der Vibrationsanalyse zur Zustandsbestimmung. Dabei entwickelte sich der Fokus von Predictive Maintenance von lediglich der anfänglichen Überwachung durch die immer größer werdenden Datenmengen hin zur ganzheitlichen Zustandsüberwachung. Durch technologische und industrielle Fortschritte wie Industrie 4.0 und dem Internet of Things wurde die Umsetzung und Implementierung von Predictive Maintenance immer einfacher und kostengünstiger. Auf diese sog. *Enabling Technologies* wird in Abs. 4.1 genauer eingegangen.

Insgesamt zeigt sich das Konzept der Predictive Maintenance als natürliche Weiterentwicklung der traditionellen Wartungsansätze aufgrund der einhergehenden technologischen Fortschritte. Während diese Arbeit lediglich Teilschritte zur Entwicklung eines Predictive Maintenance Systems beitragen will, soll anhand der Erkenntnisse und Ergebnisse die Einführung und Nutzung eines solchen Systems die offensichtliche Konsequenz sein.

Kapitel 4

Framework

Die Notwendigkeit und Bedeutung eines Predictive Maintenance Systems wurde nun in Kap. 3 beleuchtet, sowie der Fokus der Arbeit. Daher steht die Entwicklung eines funktionierenden Systems zur Anomaliedetektion an erster Stelle. In Anlehnung an Krupitzer et al. [15] werden für die Entwicklung einer Predictive Maintenance Lösung im Kontext des SSPX1 Mautüberwachungssystems einige Rahmenbedingungen skizziert. Diese lassen sich gem. Abb. 4.1 kategorisieren und werden in diesem Kapitel näher beschrieben und offengelegt. Die Zielsetzung wurde bereits in Kap. 2 erläutert und wird daher in diesem Kapitel nicht noch einmal besprochen.

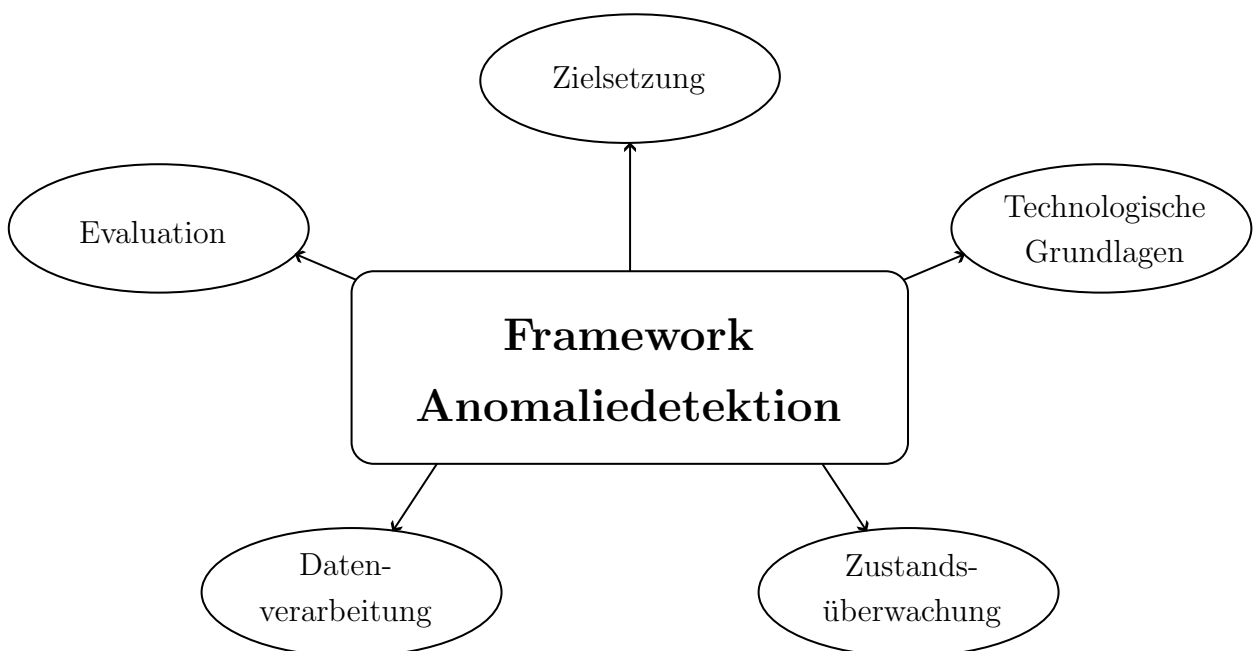


Abbildung 4.1: Framework der Entwicklung eines Systems zur Anomaliedetektion

4.1 Technologische Grundlagen

Die technologischen Grundlagen dieser Arbeit stützen sich auf die in der SSPX1 verbauten Sensoren, die präzise Systemdaten erfassen und kontinuierlich überwachen. Zu den erfassten Parametern gehören unter anderem die Temperatur und Auslastung von GPU und CPU, die Auslastung des Arbeitsspeichers sowie die Strom- und Leistungsaufnahme des Blitzmoduls.

Ein zentraler Baustein ist die Nutzung moderner IoT-Technologien in Kombination mit dem industriellen Kommunikationsstandard OPC UA. Dieser Standard basiert auf Ethernet TCP/IP und ermöglicht einen effizienten und sicheren Zugriff auf die Sensordaten der SSPX1 und deren Übertragung an eine Anwenderschnittstelle nach dem Client-Server-Prinzip [3, S. 470].

Da die Sensoren teilweise von unterschiedlichen Herstellern stammen und Messdaten in verschiedenen Formaten bereitstellen, sorgt OPC UA für eine einheitliche und standardisierte Kommunikation. Die Daten werden dabei im kompakten *OPC UA Binary*-Format [13] erfasst, wodurch eine performante und ressourcenschonende Datenübertragung ermöglicht wird. Anschließend werden die Daten an den OPC UA-Server übermittelt und in der zugrundeliegenden SQL-Datenbank gespeichert.

Durch diese Architektur wird eine herstellerübergreifende Interoperabilität gewährleistet, weshalb OPC UA besonders für den betrachteten Anwendungsfall geeignet ist. Die hohe Skalierbarkeit und Erweiterbarkeit des Standards ermöglicht zudem die einfache Integration weiterer Sensoren und Systeme, wodurch zukünftige Erweiterungen ohne grundlegende Anpassungen der bestehenden Infrastruktur möglich sind. Diese sog. *Cyber Physical Systems* ermöglichen also die Verbindung von mechanischen Komponenten über Netzwerke und sind essentiell für die Architektur dieser Arbeit.

Ein weiterer Vorteil der Nutzung von OPC UA liegt in der serviceorientierten Architektur, die eine flexible Kommunikation zwischen Client und Server ermöglicht. Der Client fungiert hierbei als Kommunikationsbrücke, die Anfragen und Antworten zwischen der Anwenderschnittstelle und dem Server verwaltet. Die OPC UA-Kommunikations-Stacks unterstützen dabei die Datenverarbeitung und gewährleisten eine robuste Übertragung, indem sie eng mit dem Speicher- und Dateisystem des Servers zusammenarbeiten. Zu den wesentlichen Ereignissen der Client-Server-Kommunikation gehören [3, 13, 17]:

- **Message Requests:** Anfragen des Clients zur Datenabfrage oder -übertragung
- **Message Responses:** Antworten des Servers auf die Anfragen des Clients
- **Order Requests:** Aufrufe zur Ausführung bestimmter Serveraktionen
- **Notifications:** Benachrichtigungen über Änderungen oder Ereignisse im System

Darüber hinaus kann der OPC UA-Server als Bindeglied zwischen mehreren physischen Geräten oder auch als Cloud-Service fungieren, was die Skalierbarkeit weiter erhöht und die Nutzung in verteilten Systemen erlaubt. Im Rahmen dieser Arbeit wird auf diese Funktionalität jedoch verzichtet, da jedes SSPX1 Gerät einen eigenen Server betreibt, der sämtliche aufgenommenen Messdaten bereitstellt.

4.2 Zustandsüberwachung

Ein wesentlicher Grund für ineffiziente Wartungsmaßnahmen liegt im unzureichenden Zugang zu Daten, die frühe Hinweise auf potenzielle Schäden oder Ausfälle liefern könnten [18, S. 2]. Predictive Maintenance basiert auf der Voraussetzung, dass Daten über den Zustand des betreffenden Systems oder der betreffenden Komponente zuverlässig verfügbar sind. Die Bereitstellung der Daten erfolgt wie oben beschrieben mithilfe von OPC UA und die Zustandsüberwachung sensorbasiert.

Zu Beginn der Arbeit und in der Entwicklungsphase wird die Zustandsüberwachung einen inspektionsbasierten Ansatz verfolgen. Das bedeutet, dass nach willkürlichen oder festgelegten Intervallen immer auf die vom OPC UA Server zur Verfügung gestellten Daten zugegriffen wird und diese Datensätze dann analysiert und weiterverarbeitet werden. Die Wahl dieser Methode basiert auf der geringeren Komplexität der Implementierung in frühen Entwicklungsphasen und hat zur Folge, dass ein konsistenter Datensatz einen besseren Vergleich und Feinabstimmung von Parametern der Analysetools ermöglicht.

Online Predictive Maintenance erweitert diesen Ansatz, indem sie eine Überwachung des Systemzustands in Echtzeit im laufenden Betrieb ermöglicht. Dabei werden Daten oder andere relevante Parameter in regelmäßigen Abständen automatisch erfasst. Nicht alle erfassten Daten werden analysiert; vielmehr wird gezielt ausgewählt, welche Informationen für die Analyse und die Ableitung von Wartungsmaßnahmen notwendig sind [16].

Die aufgenommenen Messdaten zur Zustandsüberwachung liegen als multivariate Zeitserie vor. Das bedeutet, dass alle aufgenommenen Messwerte mit einem Zeitstempel versehen sind. Dabei besteht die Möglichkeit, die Intervalle für die Messdatenaufnahme unterschiedlich einzustellen. Ein Temperaturwert unterliegt langsameren Schwankungen und kann daher in größeren Intervallen aufgenommen werden, als beispielsweise die Strom- oder Leistungsaufnahme des Blitzmoduls, wo auch kurzzeitige Spitzen und Ausreißer zuverlässig erkannt werden müssen.

4.3 Datenverarbeitung

Durch die kontinuierliche Aggregation von Messdaten der SSPX1 entstehen sehr große, hochdimensionale Datensätze. Jeder Datenpunkt in der Zeitserie S ist mehrdimensional. Eine Zeitserie ist eine Menge der Mächtigkeit n . Alle n Elemente sind reellwertige d - dimensionale Datenpunkte $S_i \in \mathbb{R}^d$ [22]. Ebenfalls lässt sich eine Zeitserie S der Länge n und Dimensionalität d als Matrix wie in Gl. 4.2a definieren. x_i^j ist der i -te Skalar der j -ten Dimension einer Serie S . Für die Dimension $j = 0, \dots, d$ der Zeitserie S entspricht jede Dimension einem Messwert im Datensatz. Da es sich um eine Zeitserie handelt, entsprechen die Indizes $i = 0, \dots, n$ den Zeitstempeln der aufgenommenen Messwerte [25]. Desweiteren wird eine *univariate* Zeitserie als eine eindimensionale Menge definiert, während eine *multivariate* Zeitserie mehrdimensionale Werte beinhaltet. Im Kontext der Arbeit sind vorrangig multivariate Zeitserien relevant.

$$S = \{ S_1, S_2, \dots, S_n \} \quad (4.1)$$

$$S = \begin{bmatrix} x_0^0 & \dots & x_0^d \\ \vdots & \ddots & \vdots \\ x_n^0 & \dots & x_n^d \end{bmatrix} \quad (a)$$

$$S = \sum_{i=0}^n \sum_{j=0}^d x_i^j \cdot E_{ij} \quad (b)$$

$$E_{32} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} \quad (c)$$

Alternativ kann die Zeitserie S gem. Gl. 4.2b auch als Linearkombination von Standardmatrizen geschrieben werden [24, S. 8]. Die elementweise Darstellung beschreibt die Matrix S als Summe von gewichteten Standardmatrizen E_{ij} , wobei jede Standardmatrix E_{ij} genau an der Position (i, j) den Wert 1 hat und sonst 0 ist. Gl. 4.2c verdeutlicht dies beispielhaft an der 4×4 Einheitsmatrix E_{32} .

Data Mining spielt in dem Zusammenhang eine große Rolle. Unter Data Mining versteht man das Finden relevanter Informationen, Muster oder Trends in großen Datensätzen. Mithilfe verschiedener Data Mining Techniken können so Voraussagen über künftige Ereignisse oder Beobachtungen getroffen werden. Der Prozess des Data Minings lässt sich anhand von Abb. 4.2 visualisieren. Dabei gehen zunächst Rohdaten aus den zahlreichen Sensoren hervor und liegen bedingt durch das SQL-Format

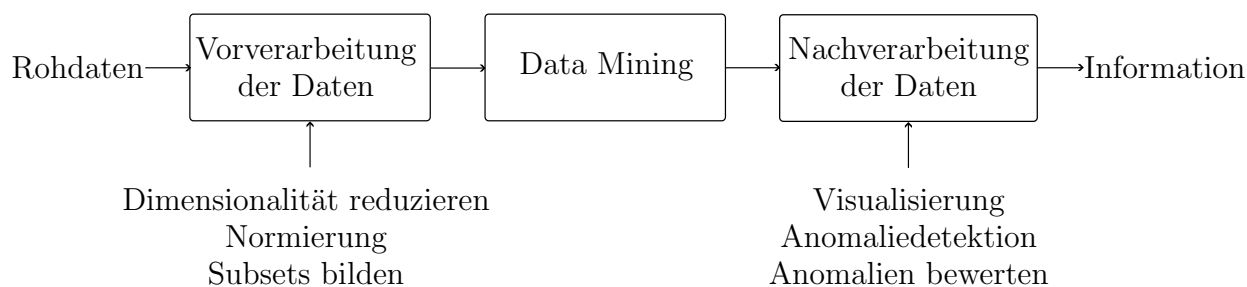


Abbildung 4.2: Typischer Data Mining Workflow vom Eingang der Quelldaten bis zum Informationsgewinn

in einer relationalen Datenbank vor. Der nächste Schritt der Vorverarbeitung erfolgt dann, damit die Daten in einem handlichen und analysierbaren Format vorliegen. Daher werden diese sowohl in ihrer Dimensionalität reduziert als auch normiert. Gegebenenfalls werden auch kontextbezogene Subsets gebildet, z. B. für Tageszeiten oder sonstige Bedingungen [23, Kap. 1].

Zur Datenverarbeitung gehören auch spezifische Herausforderungen, die die Entwicklung neuer Data Mining Techniken vorangetrieben haben. Dazu gehört unter Anderem die Skalierbarkeit eines Algorithmus, um zu gewährleisten, dass auch sehr große und immer größer werdende Datensätze mit der gleichen Präzision und Qualität verarbeitet werden. Desweiteren zählen auch die Hochdimensionalität und Heterogenität der vorliegenden Datensätze zu großen Herausforderung bei der Findung geeigneter Algorithmen. Für hochdimensionale Daten muss im Voraus im Rahmen der Vorverarbeitung eine Reduzierung der Dimensionalität stattfinden, d.h. irrelevante oder redundante Datenpunkte werden entfernt oder mit ähnlichen Datenpunkten zusammengefasst. Auch statistische Abhängigkeiten und Unabhängigkeiten sowie Korrelationen werden in diesem Schritt mit berücksichtigt. Die Heterogenität eines Datensatzes zeigt sich beispielsweise durch das Auftreten von Datenpunkten mit unterschiedlichen physikalischen Einheiten, wie Temperaturwerte und solche zur Festplattenauslastung und -schreibgeschwindigkeit. Bevor ein Datensatz also einem Algorithmus zur Anomaliedetektion übergeben werden kann, muss eine adäquate Vorverarbeitung stattfinden, denn nur so können auch relevante Ergebnisse erzeugt werden.

4.4 Evaluation

Kapitel 5

Anomaliedetektion

Anomaliedetektion beschreibt die Aufgabe, Trends, Muster und Punkte in einem Datensatz zu finden, die nicht dem Normalzustand entsprechen [9]. Anders gesagt lautet das Ziel: die Punkte finden, die sich von den anderen Punkten im Datensatz stark unterscheiden [23, Kap. 10]. Diese andersartigen Datenpunkte oder -sequenzen werden in der Regel als Anomalie, Ausreißer oder Ausnahmen bezeichnet, wobei Anomalie der geläufigste Begriff ist. Anomaliedetektion findet große Verwendung in verschiedenen Anwendungsbereichen, wie z. B. in der Netzwerktechnik zur Erkennung von potenziellen Angriffen durch Eindringlinge in ein Netzwerk anhand von ungewöhnlichem Traffic [4]. Auch in der Medizin können nach einem EKG durch Anomaliedetektion Herzrhythmusstörungen erkannt werden [10], genau wie eine Bank ein Interesse an Anomalien im Kreditkartenverhalten ihrer Kunden hat, um Betrugsfälle zu erkennen [14, 8].

Die simpelste Herangehensweise zur Erkennung von Anomalien ist die, dass zuerst definiert wird, welche Punkte im Datensatz normalem Verhalten entsprechen und alle davon abweichenden Punkte als Anomalie zu kennzeichnen. Doch so einfach die Herangehensweise wirkt, so anfällig ist sie auch für Fehler. Dabei heben sich einige Herausforderungen hervor.

Zum Einen die Frage, wo genau die Grenze zwischen normalem und anomalem Verhalten liegen soll. Eine Region zu definieren, die jeden möglichen normalen Punkt beinhaltet und jedmöglichen anomalen Punkt ausschließt, ist nicht trivial und oft nicht präzise durchführbar. So ist es durchaus möglich, dass in manchen Fällen anomale Punkte als normal bezeichnet werden, und normale Punkte als anomal, je nachdem, wo die Grenze liegt.

Es stellt sich ebenfalls die Frage, ob eine Anomalie einer binären Natur unterliegt: Entweder es handelt sich um eine Anomalie oder einen Normalzustand. Doch die Wahrheit liegt oft in der Mitte. Weicht ein Punkt oder eine Sequenz bereits nur leicht vom Normal ab, so kann es bereits erste Hinweise auf mögliches zukünftiges anomales Verhalten in einer Zeitserie geben, bevor sich solche Datenpunkte als Anomalie zeigen. Deshalb ist es hilfreich, charakterisieren zu können, wie weit der Punkt oder die Sequenz vom Normal abweicht. Diese Charakterisierung kann dabei als *Anomaly Score* bezeichnet werden und beispielsweise eine Dezimalzahl zwischen 0 und 1 sein.

Normalzustände sind in Zeitserien oft zeitvariant und daher schwer festzuhalten bei einer kontinuierli-

chen Datenaufzeichnung. Zudem sind Normalzustände und Abweichungen davon in unterschiedlichen Bereichen auch unterschiedlich signifikant. Während beim menschlichen Körper eine geringe Abweichung der Körpertemperatur bereits gravierend sein kann, ist die gleiche relative Abweichung in einer anderen Domäne wie in einem Aktienkurs weniger drastisch und unterliegt dementsprechend auch einem Anpassungsbedarf, bevor es an die Erkennung möglicher Anomalien geht.

Daraus lässt sich direkt zum nächsten Problem übergehen. Die Unterscheidung zwischen globalen und lokalen Anomalien [7]. Hier ist der Kontext wichtig: Eine Person mit einer Körpergröße von mehr als 2 m ist in ihrer Nachbarschaft sicherlich eine Anomalie, während sie in einem Basketballteam kaum herausragt - im wahrsten Sinne des Wortes. Diese Art der Anomalie wird auch als kontextuelle Anomalie bezeichnet [25, S. 12].

Doch bevor eine Auswahl an geeigneten Verfahren oder Algorithmen zur Anomaliedetektion getroffen wird, muss zuerst verstanden werden, welche verschiedenen Arten von Anomalien, im Weiteren als Kategorien bezeichnet, es gibt und wie sich diese voneinander unterscheiden. Auch wenn Studien zeigen, dass es durchaus Algorithmen gibt, die über mehrere verschiedene Kategorien gut abschneiden [25, S. 30 - 31] [22], so soll zunächst für jede Kategorie mindestens ein passender Kandidat gefunden werden. Diese werden dann in einem nächsten Schritt kreuzweise getestet, um auch solche Allrounder entdecken zu können. Dabei ist auch immer der Kontext der Anwendung wichtig. Wie eingangs erwähnt, sind für verschiedene Tätigkeitsfelder verschiedene Anforderungen an die Präzision oder Genauigkeit gestellt, weshalb immer die spezifischen Anforderung bedacht werden müssen, und nicht jeder Algorithmus gleich performant ist über mehrere Datensätze hinweg.

Für die Kategorien wird sich zunächst auf wenige, für diese Arbeit relevante, beschränkt: **Punktanomalien**, **Subsequenzanomalien** und **Korrelationsanomalien**, abgeleitet von Chandola et al. [9].

5.1 Punktanomalien

Ein einzelner Datenpunkt, der stark von den anderen Punkten im Datensatz abweicht, heißt Punktanomalie [9]. Genauer gesagt, wenn ein Datenpunkt weit außerhalb der Wahrscheinlichkeitsverteilung des Datensatzes liegt, ist er anomal [23, Kap. 10]. Punktanomalien können recht leicht erkannt werden, da Punktanomalien stark vom Mittelwert und vom Median des Datensatzes abweichen. Wenn von Ausreißern gesprochen wird, sind damit typischerweise Punktanomalien gemeint.

Als Beispielszenario dient ein Smart Meter, das den stündlichen Stromverbrauch misst. In Abb. 5.1a ist der gemessene Stromverbrauch dargestellt mit einer klar erkennbaren Punktanomalie am 01.08. um 18 Uhr. Die Anomalie wird mit bloßem Auge deutlich und kann auch mit statistischen Größen nachgewiesen werden, wie in Abb. 5.1b anhand der Häufigkeitsverteilung und dem Mittelwert sowie dem Median zu sehen ist. Das Histogramm dient als gute Approximation für die Wahrscheinlichkeitsverteilung der Messwerte, und zeigt entsprechend die Eindeutigkeit des Ausreißers.

Um nun eine Aussage treffen zu können, ist es wichtig den Kontext der vorliegenden Daten zu kennen. Wenn Daten für ein weitaus größeres Zeitfenster vorliegen, z. B. für eine Woche oder einen Monat,

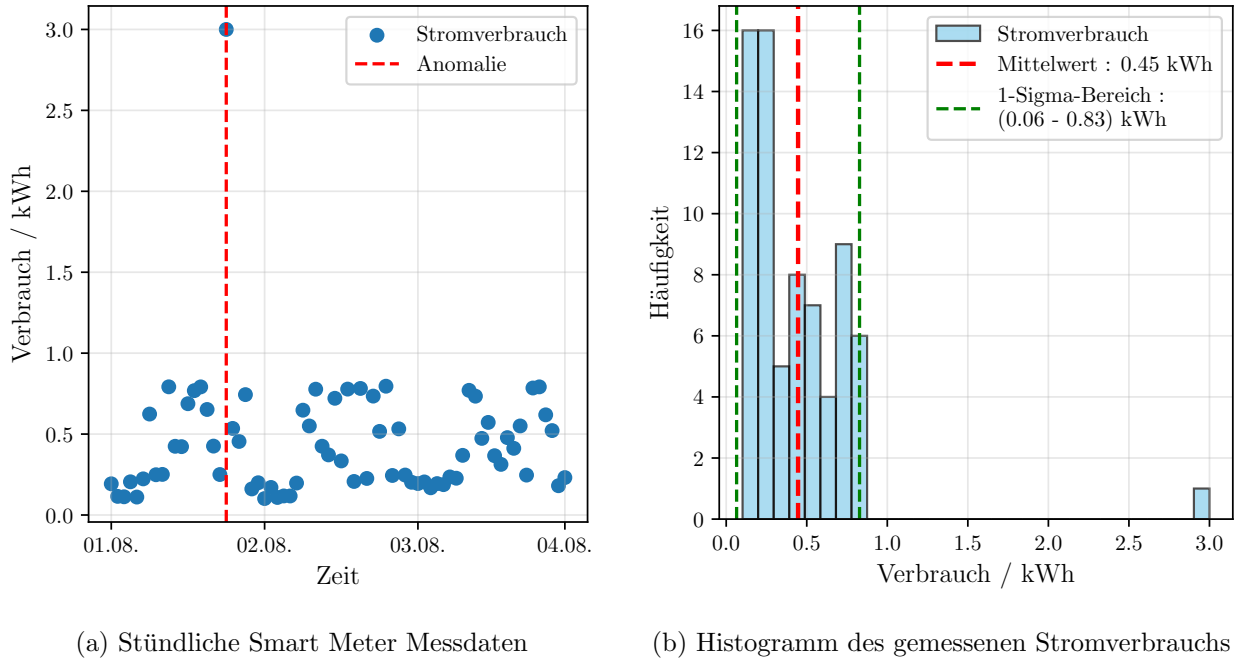


Abbildung 5.1: Beispielszenario einer Punktanomalie: Stromverbrauch eines Haushaltes über den Zeitraum von drei Tagen. Anhand des Histogramms wird die Anomalie verdeutlicht.

könnte sich möglicherweise zeigen, dass der hohe Verbrauch öfter und regelmäßiger vorkommt als im gezeigten Zeitraum von drei Tagen. Ob eine globale oder lediglich eine lokale Anomalie vorliegt, wird mit einem größeren Datensatz besser erkennbar. Die Anomalie könnte beispielsweise auf das gelegentliche Betreiben einer Sauna im Haus zurückführbar sein, dann würde es sich lediglich um eine lokale Anomalie handeln und in einem größeren Zeitraum in bestimmten Abständen öfter vorkommen, und wäre somit keine globale Anomalie [23, Kap. 10].

Punktanomalien sind im Kontext dieser Arbeit tendenziell weniger relevant, sollen aber aufgrund ihrer grundsätzlichen Bedeutung bzgl. Anomaliendetektion als einfachste Kategorie trotzdem beleuchtet werden, um entsprechende Algorithmen, die der Erkennung solcher Punktanomalien zuzuordnen sind, auch gegenüber anderen Anomalien zu testen.

5.2 Subsequenzanomalien

Eine Zeitserie wird gem. Gl. 4.1 bereits als eine Menge definiert. Demnach wird eine Subsequenz $S_{i,j} = \{S_i, \dots, S_j\} \subseteq S$ von der Zeitserie S umfasst, mit der Länge oder Mächtigkeit $|S_{i,j}| = j - i + 1$ und $|S_{i,j}| \geq 1$ [22]. Subsequenzanomalien sind Muster in Zeitreihen, die von anderen Mustern innerhalb der gleichen Zeitreihe abweichen [9][25, S. 12]. Im Gegensatz zu Punktanomalien beziehen sich Subsequenzanomalien auf mehrere konsekutive Datenpunkte, die ein ungewöhnliches Muster bilden. Eine anomale Subsequenz kann also bedeuten, dass die Datenpunkte innerhalb der Subsequenz Werte in einem normalen, zu erwartenden Bereich annehmen, aber der zu Grunde liegende Trend ungewöhnlich ist [9][6, S. 17]. Solche ungewöhnlichen oder einzigartigen Trends und Entwicklungen können auf zukünftig auftretende Probleme hindeuten, die sonst unentdeckt bleiben würden.

Literaturverzeichnis

- [1] Khoulood Abdelli. “Machine Learning-Based Predictive Maintenance for Optical Networks”. PhD thesis. Kiel, 2022. URL: <https://nbn-resolving.org/urn:nbn:de:gbv:8:3-2023-00225-4>.
- [2] J. D. Andrews and T. R. Moss. *Reliability and Risk Assessment*. English. Vol. 2nd ed. London: John Wiley and Sons, Inc, 2002. ISBN: 1-86058-290-7.
- [3] Wolfgang Babel. *Systemintegration in Industrie 4.0 und IoT. Vom Ethernet bis hin zum Internet und OPC UA*. 1st ed. 2024. Wiesbaden: Imprint: Springer Vieweg, 2024. 1585216161 pp. ISBN: 9783658429874.
- [4] Jarosław Bernacki and Grzegorz Kołaczek. “Anomaly Detection in Network Traffic Using Selected Methods of Time Series Analysis”. In: *International Journal of Computer Network and Information Security* 7.9 (Aug. 2015), pp. 10–18. ISSN: 2074-9104. DOI: 10.5815/ijcnis.2015.09.02.
- [5] M Bevilacqua and M Braglia. “The analytic hierarchy process applied to maintenance strategy selection”. In: *Reliability Engineering & System Safety* 70.1 (Oct. 2000), pp. 71–83. ISSN: 0951-8320. DOI: 10.1016/S0951-8320(00)00047-8.
- [6] Paul Boniol and Themis Palpanas. “Detection of anomalies and identification of their precursors in large data series collections”. PhD thesis. 2021. URL: <http://www.theses.fr/2021UNIP5206/document>.
- [7] Markus M. Breunig et al. “LOF: Identifying Density-Based Local Outliers”. In: *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*. SIGMOD/PODS00. ACM, May 2000, pp. 93–104. DOI: 10.1145/342009.335388.
- [8] V. Ceronmani Sharmila et al. “Credit Card Fraud Detection Using Anomaly Techniques”. In: *2019 1st International Conference on Innovations in Information and Communication Technology (ICIICT)*. IEEE, Apr. 2019, pp. 1–6. DOI: 10.1109/iciict1.2019.8741421.
- [9] Varun Chandola, Arindam Banerjee, and Vipin Kumar. “Anomaly detection: A survey”. In: *ACM Computing Surveys* 41.3 (July 2009), pp. 1–58. ISSN: 1557-7341. DOI: 10.1145/1541880.1541882.
- [10] Sucheta Chauhan and Lovekesh Vig. “Anomaly detection in ECG time signals via deep long short-term memory networks”. In: *2015 IEEE International Conference on Data Science and Advanced Analytics (DSAA)*. IEEE, Oct. 2015, pp. 1–7. DOI: 10.1109/dsaa.2015.7344872.

- [11] E. Deloux, B. Castanier, and C. Bérenguer. “Predictive maintenance policy for a gradually deteriorating system subject to stress”. In: *Reliability Engineering & System Safety* 94.2 (Feb. 2009), pp. 418–431. ISSN: 0951-8320. DOI: 10.1016/j.ress.2008.04.002.
- [12] Ziquan Deng et al. “A Reliable Framework for Human-in-the-Loop Anomaly Detection in Time Series”. In: *ArXiv* abs/2405.03234 (2024). URL: <https://api.semanticscholar.org/CorpusID:269605667>.
- [13] International Electrotechnical Commission. *IEC 62541-1: OPC Unified Architecture – Part 5: Information Model*. Accessed: 2024-12-16. IEC, 2020. URL: <https://webstore.iec.ch/en/publication/61114>.
- [14] Shanshan Jiang et al. “Credit Card Fraud Detection Based on Unsupervised Attentional Anomaly Detection Network”. In: *Systems* 11.6 (June 2023), p. 305. ISSN: 2079-8954. DOI: 10.3390/systems11060305.
- [15] Christian Krupitzer et al. “A Survey on Predictive Maintenance for Industry 4.0”. In: *ArXiv* abs/2002.08224 (2020). URL: <https://api.semanticscholar.org/CorpusID:211171556>.
- [16] John Lindström et al. “Towards Intelligent and Sustainable Production: Combining and Integrating Online Predictive Maintenance and Continuous Quality Control”. In: *Procedia CIRP* 63 (2017), pp. 443–448. ISSN: 2212-8271. DOI: 10.1016/j.procir.2017.03.099.
- [17] Bingqiang Mao et al. “OPC UA Application Study in Oil and Gas Pipeline Network Monitoring Data Forwarding”. In: *EAI Endorsed Transactions on Energy Web* 11 (Mar. 2024). ISSN: 2032-944X. DOI: 10.4108/ew.5245.
- [18] R. Keith Mobley. *An Introduction to Predictive Maintenance*. Plant Engineering. Butterworth-Heinemann, 2002. ISBN: 9780080478692.
- [19] John T. Renwick and Paul E. Babson. “Vibration Analysis—A Proven Technique as a Predictive Maintenance Tool”. In: *IEEE Transactions on Industry Applications* IA-21.2 (Mar. 1985), pp. 324–332. ISSN: 0093-9994. DOI: 10.1109/tia.1985.349652.
- [20] H. Sandtorv, G. Fiskaa, and M. Rasmussen. “Datatrend, A computerized System for Engine Condition Monitoring and Predictive Maintenance of Large Bore Diesel Engines”. In: *IFAC Proceedings Volumes* 6.3 (1973), pp. 252–266. ISSN: 1474-6670. DOI: 10.1016/S1474-6670(17)68133-3. URL: <https://www.sciencedirect.com/science/article/pii/S1474667017681333>.
- [21] C. Scheffer and P. Girdhar. *Practical Machinery Vibration Analysis and Predictive Maintenance*. Practical Machinery Vibration Analysis and Predictive Maintenance. Newnes, 2004. ISBN: 9780080480220. URL: <https://books.google.de/books?id=tAvT01t2mwkC>.
- [22] Sebastian Schmidl, Phillip Wenig, and Thorsten Papenbrock. “Anomaly detection in time series: a comprehensive evaluation”. In: *Proceedings of the VLDB Endowment* 15.9 (May 2022), pp. 1779–1797. ISSN: 2150-8097. DOI: 10.14778/3538598.3538602.
- [23] Pang-Ning Tan, Michael Steinbach, and Vipin Kumar. *Introduction to data mining*. New international edition. Always learning. Harlow: Pearson, 2014. 732 pp. ISBN: 9781292026152.
- [24] Christian Voigt and Jürgen Adamy. *Formelsammlung der Matrizenrechnung*. Technik 10-2012. München: Oldenbourg, 2012. 162 pp. ISBN: 9783486583502.

- [25] Phillip Wenig. “Finding, Clustering, and Classifying Anomalies on Large and Multivariate Time Series”. Dissertation. Universität Potsdam, 2024. DOI: 10.25932/publishup-66043. URL: <https://publishup.uni-potsdam.de/frontdoor/index/index/docId/66043>.